

Reporte de Progreso

Equipo Aragorn | Competencia de Inversion Inmobiliaria Miami

Fecha: 09/06/2026

Objetivo de la competencia

Predecir el precio de venta de propiedades residenciales en Miami / Sur de Florida. Las predicciones se evaluan mediante una simulacion Monte Carlo de inversion inmobiliaria donde el modelo mas preciso genera mayor ROI.

1. Estado del entorno

Python:	3.14.5
LightGBM:	4.6.0
pandas:	3.0.3
numpy:	2.4.6

Dataset disponible

- train_processed.csv -- 11,840 filas (features + target)
- test_processed.csv -- 5,038 filas (sin target)
- train_photo_metadata.csv + test_photo_metadata.csv
- ~199,000 fotos JPG de propiedades (data/images/props/)

2. Modelos entrenados

Ronda 1 -- Baseline LightGBM (models/baseline_lgbm.py)

LightGBM con cross-validation 5-fold (random_state=42). Entrena sobre el espacio completo de features tabulares sin segmentacion. Incluye imputacion de missing values por mediana dentro de homeType y early stopping en 50 rondas.

OOF MAPE:	26.51%
OOF MAE:	\$119,372
Test submission:	submissions/baseline_lgbm.csv (5,038 filas)
OOF Practice:	submissions/oof_baseline_lgbm.csv (11,840 filas)

Ronda 2 -- Segmented LightGBM (models/round2_segments.py)

Extiende el baseline con feature engineering avanzado y modelos separados por segmento de propiedad (SINGLE_FAMILY / CONDO / REST). Los features de ZIP (basados en el target) se calculan dentro de cada fold para evitar leakage.

Features nuevos incorporados:

- Ratios financieros: tax_per_sqft, listing_to_tax_ratio, tax_to_area, hoa_to_area
- Scores compuestos: luxury_score (pool+waterfront+garage+HOA), distress_score (foreclosure+price_cut)
- Interacciones: school_x_area, waterfront_x_lat, age_x_school, beds_x_baths
- Agregaciones ZIP dentro del fold: zip_median_log_price, zip_std_log_price, zip_count, zip_median_area, zip_price_per_sqft_median

OOF MAPE global:	27.06%
OOF MAE global:	\$121,714
MAPE por segmento:	SF=28.61% CONDO=26.10% REST=25.68%
Test submission:	submissions/round2_segments.csv (5,038 filas)

OOF Practice: submissions/oof_round2_segments.csv (11,840 filas)

3. Resultados Practice Simulation (dashboard)

Ambos modelos fueron subidos al tab Practice del dashboard. La simulacion corre 1,000 iteraciones Monte Carlo con 4 rondas internas de 250 propiedades cada una (4,000 observaciones round-level en total).

Modelo	wMAPE (%)	Mean ROI (%)	Median ROI (%)	Std ROI (%)	Sharpe	Hit Rate (%)
baseline (unlabeled)	21.35	23.27	20.91	20.24	1.150	68.62
round2_segments	21.77	20.63	18.16	19.42	1.063	66.99

Interpretacion de resultados

- El baseline supera al round2 en ROI (+2.6pp) y Sharpe (1.15 vs 1.06).
- El round2 tiene ligeramente menor Std ROI, pero su media es inferior.
- El feature engineering de Ronda 2 no mejoro la simulacion -- posible sobreajuste en REST (solo 2,217 props).
- La metrica clave es ROI de simulacion, no MAPE: un modelo puede tener mejor MAPE y peor ROI si sus errores estan mal calibrados para la estrategia de compra.

4. Bugs encontrados y corregidos

Bug 1 -- Categorías desalineadas en prediccion por segmento

Al filtrar el test set por segmento (SF/CONDO/REST), las columnas categoricas (homeType, zipcode) tenian niveles distintos a los del fold de entrenamiento, causando ValueError en LightGBM al predecir.

Fix: alinear categorias de train y test una vez tras el preprocesamiento usando .cat.set_categories() con la union de ambos sets.

Bug 2 -- Indices OOF incorrectos tras merge de ZIP features

La funcion add_zip_features() realiza un merge que resetea el indice del DataFrame. Al guardar predicciones OOF con val_seg.index, se escribia en posiciones erroneas, produciendo un OOF MAPE global de 98.57% (vs ~27% real por fold).

Fix: guardar los indices originales en columna _orig_idx antes del merge y usarlos para indexar oof_preds[].

5. Roadmap de modelos

Ronda	Archivo	Estado	Descripcion
1	baseline_lgbm.py	Listo	LightGBM tabular completo, CV 5-fold
2	round2_segments.py	Listo	Feature eng. + modelos por segmento SF/CONDO/REST
3	--	Pendiente	Embeddings de imagenes (CLIP o ResNet, foto principal)
4	--	Pendiente	Ensemble completo + calibracion de predicciones

Proximos pasos prioritarios

- Analizar drill-down del dashboard: identificar propiedades donde el modelo falla sistematicamente.
- Implementar embeddings de imagenes con CLIP (base en scripts/02_image_embeddings.py).
- Evaluar calibracion: el modelo subestima precios altos (max predicho \$1.56M vs rango real hasta \$1.99M).
- Investigar por que round2 pierde vs baseline: posible sobreajuste en segmento REST.

6. Mecanica de evaluacion (referencia)

La simulacion Monte Carlo replica el mercado inmobiliario con los siguientes parametros:

- asking_price = true_value x (1 + Normal(-0.07, 0.35))
- Compramos si: prediccion > asking_price x 1.08

- Nuestra oferta en subasta: prediccion x 0.85
- Subasta Vickrey: gana el mayor postor, paga el segundo precio

Capital inicial: \$5M por ronda. 4 rondas internas por simulacion. 1,000 simulaciones Monte Carlo. Ganador: equipo con mayor win rate (% de simulaciones en 1er lugar).