



UNIVERSIDAD AUSTRAL

MDM Austral 2026 · Labo 2

Property Investment Competition

Desarrollo del proyecto, estrategia y resultados

Equipo SAM

Modelo final: round8_distress_fix_scale083.csv

Contenido: mecanica del juego, los datos, cronologia ronda a ronda, Ronda 9 en detalle, calibracion de escala, criterio de Kelly, aprendizajes y recomendacion final.

2026-07-18

Objetivo y mecanica de la competencia

Es una competencia de inversion inmobiliaria simulada. Predecimos el precio de venta de propiedades en Miami / Sur de Florida, y esa prediccion se usa para decidir, en una simulacion, si compramos cada propiedad y cuanto ofertamos.

Como funciona cada simulacion

- ▶ Cada propiedad tiene un precio de oferta (asking price) generado al azar alrededor del valor real: $\text{asking} = \text{valor_real} \times (1 + \text{Normal}(-7\%, 35\%))$.
- ▶ Compramos solo si nuestra prediccion supera el asking price en un 8% ($\text{pred} > \text{asking} \times 1.08$).
- ▶ Si compramos, ofertamos $\text{pred} \times 0.85$ en una subasta Vickrey: gana el mayor postor pero paga el precio del segundo postor.
- ▶ Se corren 1,000 simulaciones Monte Carlo, 4 rondas por simulacion, capital de \$5M por ronda.
- ▶ Gana el equipo con mayor Mean ROI promedio (metrica principal). El Win Rate es secundario: no decide el ganador.

Que significa esto en la practica

Si predecimos MUY POR ENCIMA del valor real, compramos propiedades caras y perdemos plata (perdida real). Si predecimos por debajo, simplemente no compramos esa propiedad (perdemos la oportunidad, pero no perdemos capital). Este desbalance — sobreestimar es mucho mas costoso que subestimar — explica varias de las decisiones de diseno del proyecto (ver Ronda 4, mas adelante).

Los datos con los que trabajamos

Dos conjuntos de propiedades

- ▶ Train: 11,840 propiedades con precio de venta real conocido — con esto entrenamos los modelos.
- ▶ Test: 5,038 propiedades sin precio — sobre estas generamos las predicciones que se usan en la competencia real.

Que sabemos de cada propiedad

- ▶ Datos estructurados: tamaño, habitaciones, baños, antigüedad, ubicación, impuestos, escuelas cercanas, HOA, historial de precio.
- ▶ Fotos de la propiedad (usadas en Rondas 3 a 8 via embeddings CLIP).
- ▶ Descripción de texto (usada en el experimento de Ronda 9).

Dificultades del dataset

- ▶ Faltantes importantes: lotAreaValue (45% de las filas), last_listing_price (33%).
- ▶ Features "filtradas" (leaky): taxAssessedValue y variables de impuestos correlacionan mucho con el precio pero no explican por que vale eso — se usan con cuidado, no como única fuente de señal.
- ▶ Un número chico de propiedades (menos del 2%) son ventas atípicas (remates, ventas familiares forzadas, etc.) con precio real muy por debajo de lo esperado — estas pocas propiedades terminaron siendo el factor más importante de todo el proyecto (ver Rondas 3, 4 y 8).

Rondas 1 a 3 — primeros pasos

Ronda 1 · 2026-06-09

OK

Baseline LightGBM

Primer modelo: LightGBM con todos los features tabulares disponibles y validacion cruzada 5-fold.

wMAPE ~26% · Practice: Mean ROI 23.27%, Sharpe 1.15

Ronda 2 · 2026-06-09

NO FUNCIONO / EMPEORO

Segmentacion + Feature Engineering

Modelos separados por tipo de propiedad (SINGLE_FAMILY / CONDO / RESTO) mas ratios financieros, scores compuestos (lujo, distress) e interacciones.

Practice: Mean ROI 20.63%, Sharpe 1.06 — PEOR que Ronda 1

Leccion: Mas feature engineering no garantiza mejor resultado.

Ronda 3 · 2026-06-11

OK

Deteccion de "distressed sales ocultas"

Encontramos 16 propiedades con perdidas catastroficas: el impuesto (taxAssessedValue) era 1.3x a 6.8x el precio real de venta, sin ninguna bandera de foreclosure que las delatara. El modelo las sobre-predecia sistematicamente. Se agregaron features de ZIP relativas (tax_vs_zip_ratio, is_tax_outlier) y un techo (cap)

OOF MAPE 27.0% · Sharpe 1.074 vs 1.049 de Ronda 2

Rondas 3-4 a 4 — imagenes y regresion cuantil

Ronda 3-4 · 2026-06-27

MEJORA GRANDE

Embeddings de imagenes (CLIP)

Se proceso la foto principal de cada propiedad con CLIP (red neuronal de vision-lenguaje) y se redujo a 32 componentes principales (PCA). Tambien se calculo un score visual de deterioro (clip_distress_score) de forma zero-shot, sin entrenar nada especifico.

wMAPE 22.4% · Practice: Mean ROI 49.7% (+92% vs ronda anterior)

Leccion: El score visual de distress no mejoro el error promedio global, pero mejoro muchisimo la seleccion de que..

Ronda 4 · 2026-06-26

MEJORA GRANDE

Regresion cuantil (percentil 35, no la media)

Detectamos que 2 propiedades causaron el 52% de todas las perdidas acumuladas (el modelo las habia sobre-predicho 5.7x y 8.8x el valor real). El error es asimetrico en este juego: sobreestimar destruye capital (compramos caro), subestimar solo cuesta la oportunidad (no compramos). Por eso se cambio el modelo para

Practice: Mean ROI 44.47%, Sharpe 2.05, Prob. positivo 99.2%

Simulador propio · 2026-06-26

OK

Monte Carlo local calibrado con datos reales

Se construyo un simulador local que reproduce exactamente la mecanica del dashboard, calibrado con 946 ofertas reales observadas de 6 equipos rivales en una ronda de competencia ya jugada. Sirve para probar ideas sin gastar rondas reales ni subir al dashboard cada vez.

En la calibracion inicial, nuestro equipo ganaba el 34.3% de las simulaciones

Rondas 5 a 7 — calibrando la agresividad

Ronda 5 · 2026-06-27

OK

Mas conservador, penalidad dura a foreclosure

Se valido que $\alpha=0.35$ (Ronda 4) era el punto correcto: bajarlo a 0.30 hundia el win rate de 34.3% a 12.4%. En una subasta Vickrey, predecir demasiado bajo simplemente regala las propiedades buenas a los competidores. Tambien se descarto last_listing_price como señal de distress: 22% del train tiene ese ratio

Confirma $\alpha=0.35$ como calibracion base

Ronda 6 · 2026-06-27

RESULTADO MIXTO

Experimento: prediccion central + descuento quirurgico

Se probó $\alpha=0.50$ (predicción central, no conservadora) buscando comprar mas volumen, compensando con un descuento solo a las propiedades con peor score visual de distress (percentil 90).

Mas volumen de compra, pero mayor tasa de errores costosos

Ronda 7 · 2026-07-03

RESULTADO MIXTO

Punto intermedio: $\alpha=0.42$

En una ronda real, un equipo competidor gano comprando mucho mas volumen (15.4 props/ronda) que nosotros (9.7 props/ronda) aunque con menor precision por compra. Se probó $\alpha=0.42$ como punto intermedio entre conservador y agresivo.

Buscando 12-13 props/ronda con hit rate > 65%

Rondas 8 y 9, y la calibracion final

Ronda 8 · 2026-07-03

MEJORA GRANDE

Fix quirurgico final (mejor modelo)

Se uso el resultado REAL de subastas ya jugadas (exports de la competencia) para identificar con certeza 6 propiedades donde el modelo se equivoco por hasta 4x el valor real. Se forzo su prediccion a $\text{valor_real} \times 0.92$. Se agrego ademas un detector automatico para el train set: cualquier propiedad con ratio

Se convirtio en el mejor modelo del proyecto hasta la calibracion final

Ronda 9 · 2026-07-03 a 2026-07-18

NO FUNCIONO / EMPEORO

Intento con texto (LLM local)

Se extrajeron ~18 features semanticas (condicion, vista, penthouse, amenities, señales de distress) de las descripciones de las propiedades usando un modelo de lenguaje corriendo LOCAL y gratis (Ollama, Qwen2.5 1.5B). Cobertura real: 48% de las propiedades tenian descripcion procesable.

Pausado: no aporta con la calidad/cobertura de extraccion actual

Leccion: Mas señal no es necesariamente buena señal si es ruidosa o parcial.

Calibracion final · 2026-07-18


MEJORA GRANDE

Barrido de escala sobre Ronda 8

Con Ronda 8 como mejor modelo, se probó multiplicar todas sus predicciones por un factor de escala (arriba y abajo de 1.0) para ver el efecto en el ROI. Primero se validó con el simulador local (calibrado con datos reales de subastas pasadas): se encontró una meseta óptima entre 0.80 y 0.85, con el Mean ROI subiendo de

Mejora real, grande y reproducible — validada en 3 corridas independientes

Ronda 9 — por que el texto no ayudo




Prueba de proxies para detectar "distressed" en el test set

Ninguno predijo mejor que el azar (tasa base: 1.66%):

tag_foreclosure	precision 0.0% (recall 0.0%)
num_price_changes > 2	precision 1.0% (recall 12.2%)
clip_distress_score > 0.7	precision 2.0% (recall 4.6%)
llm_is_fixer	precision 3.4% (recall 17.8%)
raw_listing_to_tax < 0.5	precision 1.6% (recall 22.3%)

Conclusion: las perdidas catastróficas parecen ser idiosincráticas (circunstancias del vendedor), no un patrón detectable en fotos, tags o descripciones. Se descarto la corrección automática basada en proxies.

La calibracion final: barrido de escala



Meseta optima entre escala 0.80 y 0.85: el Mean ROI local sube de 8.26% (sin escalar) a ~10.1-10.3% (+24% relativo). Validado en el dashboard real con 3 corridas independientes, cada una con un campo competitivo distinto:

Corrida	N° modelos	Escala 0.83	Escala 0.85	Ronda 8 (sin escalar)
#1	3	76.5%	31.4%	27.0%
#2	7	61.2%	30.1%	15.5%
#3	9	46.9%	29.1%	11.0%

El orden nunca se invirtio: escala 0.83 > escala 0.85 > Ronda 8 sin escalar, en las 3 corridas. Por eso se adopto la escala 0.83 con confianza.

Criterio de Kelly aplicado a la subasta

Kelly clasico asume que perder = perder toda la apuesta. Ese no es nuestro caso: si nos gana la subasta, no perdemos nada (el capital queda intacto). Lo adaptamos a lo que realmente puede pasar — ganar la subasta y pagar de mas — condicionado a que ganamos:

$$f^* = p/L - q/W$$

p = Hit Rate (prob. de que la compra sea rentable) · $q = 1-p$ · W = ganancia media como fraccion del costo, cuando es rentable · L = perdida media como fraccion del costo, cuando no lo es.

Segmento	Hit Rate	Ganancia (W)	Perdida (L)	Kelly f^*	Escala
SF	75.0%	30.8%	19.3%	3.08	0.828
CONDO	70.5%	30.4%	16.6%	3.28	0.832
REST	72.7%	30.0%	17.8%	3.17	0.83

Resultado honesto

Los 3 segmentos resultaron con un perfil de riesgo bastante parecido (Hit Rate 70-75% en los tres), asi que Kelly sugiere una escala muy cerca de la plana ya validada (0.83)— no una diferenciacion dramatica. Aun asi, escalar por segmento en vez de plano mejoro el Mean ROI local de 9.95% a 10.15%.

Mean ROI local: escala plana 0.83 = 9.95% → escala Kelly por segmento = 10.15%

LECCION: Kelly aca no descubre una mejora dramatica — confirma que nuestra escala

plana ya estaba cerca del optimo, con un margen chico para afinar por segmento.

Pendiente de validar en el dashboard real de Practice.

Aprendizajes clave y recomendacion final

1. El error promedio no es lo que gana la competencia

En Ronda 4 encontramos que 2 propiedades causaron el 52% de todas las perdidas. Bajar el MAPE global importa menos que eliminar esos pocos errores extremos que destruyen capital.

2. Mas features no siempre ayudan

Ronda 2 (mas feature engineering) y Ronda 9 (features de texto por LLM) empeoraron el modelo. Hay que medir cada cambio, no asumir que suma.

3. Calibrar cuanto arriesgar importa tanto como el modelo en si

El ajuste final de escala (multiplicar las predicciones por 0.83) genero una mejora de ROI comparable a la de agregar imagenes — y costo una tarde de trabajo, no semanas.

4. Validar siempre en Practice antes de gastar una ronda real

Cada modelo nuevo se subio primero como OOF al tab Practice del dashboard. Solo se uso una ronda real cuando el Practice confirmaba una mejora.

5. Desconfiar de una sola corrida

La simulacion de Practice varia segun cuantos modelos compiten a la vez en la misma corrida. Antes de decidir, se repitieron las comparaciones clave 2 o 3 veces para confirmar que la diferencia era real y no ruido del muestreo Monte Carlo.

MODELO ELEGIDO PARA LA PROXIMA RONDA

round8_distress_fix_scale083.csv

Es el modelo de Ronda 8 (tabular + imagenes CLIP + fix quirurgico de propiedades distressed confirmadas) con todas las predicciones escaladas x0.83. Es la combinacion que mejor Mean ROI mostro de forma consistente en validaciones repetidas, tanto en simulacion local como en el dashboard real de Practice.