



**UNIVERSIDAD AUSTRAL**

MDM Austral 2026 · Labo 2

# Property Investment Competition

Desarrollo del proyecto, estrategia y resultados

## Equipo SAM

Modelo final: round8\_distress\_fix\_scale083.csv

Contenido: mecanica del juego, los datos, cronologia ronda a ronda, Ronda 9 en detalle, calibracion de escala, criterio de Kelly, aprendizajes y recomendacion final.

2026-08-03

## Objetivo y mecanica de la competencia

Es una competencia de inversion inmobiliaria simulada. Predecimos el precio de venta de propiedades en Miami / Sur de Florida, y esa prediccion se usa para decidir, en una simulacion, si compramos cada propiedad y cuanto ofertamos.

### Como funciona cada simulacion

- ▶ Cada propiedad tiene un precio de oferta (asking price) generado al azar con una distribucion normal (gaussiana), media -7% y desvio 35%:  $\text{asking} = \text{valor\_real} \times (1 + \text{Normal}(-7\%, 35\%))$ . En criollo: el asking suele salir un poco por debajo del valor real, pero con mucha variacion — a veces sale muy bajo, a veces muy alto.
- ▶ Compramos solo si nuestra prediccion supera el asking price en un 8% ( $\text{pred} > \text{asking} \times 1.08$ ).
- ▶ Si compramos, ofertamos  $\text{pred} \times 0.85$  en una subasta Vickrey (gana el mayor postor pero paga el precio del segundo postor). Ese  $\times 0.85$  es una regla fija de la competencia, no algo que ajustamos nosotros — lo que si calibramos es la prediccion que entra a esa formula (alpha, escala).
- ▶ Se corren 1,000 simulaciones Monte Carlo, 4 rondas por simulacion, capital de \$5M por ronda.
- ▶ Gana el equipo con mayor Mean ROI promedio (metrica principal). El Win Rate es secundario: no decide el ganador.

### Que significa esto en la practica

Si predecimos MUY POR ENCIMA del valor real, compramos propiedades caras y perdemos plata (perdida real). Si predecimos por debajo, simplemente no compramos esa propiedad (perdemos la oportunidad, pero no perdemos capital). Este desbalance — sobreestimar es mucho mas costoso que subestimar — explica varias de las decisiones de diseno del proyecto (ver Ronda 4, mas adelante).

# Los datos con los que trabajamos

## Dos conjuntos de propiedades

- ▶ Train: 11,840 propiedades con precio de venta real conocido — con esto entrenamos los modelos.
- ▶ Test: 5,038 propiedades sin precio — sobre estas generamos las predicciones que se usan en la competencia real.

## Que sabemos de cada propiedad

- ▶ Datos estructurados: tamaño, habitaciones, baños, antigüedad, ubicación, impuestos, escuelas cercanas, HOA, historial de precio.
- ▶ Fotos de la propiedad (usadas en Rondas 3 a 8 via embeddings CLIP).
- ▶ Descripción de texto (usada en el experimento de Ronda 9).

## Dificultades del dataset

- ▶ Faltantes importantes: lotAreaValue (45% de las filas), last\_listing\_price (33%).
- ▶ Features "filtradas" (leaky): taxAssessedValue y variables de impuestos correlacionan mucho con el precio pero no explican por que vale eso — se usan con cuidado, no como única fuente de señal.
- ▶ Un número chico de propiedades (menos del 2%) son ventas atípicas (remates, ventas familiares forzadas, etc.) con precio real muy por debajo de lo esperado — estas pocas propiedades terminaron siendo el factor más importante de todo el proyecto (ver Rondas 3, 4 y 8).

## Rondas 1 y 2 — primeros pasos

Ronda 1 · 2026-06-09

OK

### Baseline LightGBM

Primer modelo: LightGBM con todos los features tabulares disponibles y validacion cruzada 5-fold.

**wMAPE ~26% · Practice: Mean ROI 23.27%, Sharpe 1.15**

Ronda 2 · 2026-06-09

NO FUNCIONO / EMPEORO

### Segmentacion + Feature Engineering

Dos tecnicas distintas, probadas juntas en la misma ronda.

(1) Segmentacion: en vez de un solo modelo, se entrenaron 3 modelos separados, uno por tipo de propiedad (SINGLE\_FAMILY / CONDO / RESTO) — no es una columna nueva, es una decision de arquitectura.

(2) Feature engineering: columnas nuevas calculadas a partir de las existentes — ratios financieros (ej. tax\_per\_sqft = impuesto / superficie), scores compuestos (ej. luxury\_score = suma de pileta + vista al agua + garage + HOA alto) e interacciones (ej. school\_x\_area = rating de escuela x superficie).

**Practice: Mean ROI 20.63%, Sharpe 1.06 — PEOR que Ronda 1**

*Leccion: Mas feature engineering no garantiza mejor resultado. Hay que medir cada cambio en Practice antes de asumir que mejora. Como las dos tecnicas se probaron juntas, no sabemos cual de las dos causo la caida.*

## Ronda 3 y 3-4 — distressed ocultas e imagenes

Ronda 3 · 2026-06-11

OK

### Deteccion de "distressed sales ocultas"

Encontramos 16 propiedades con perdidas catastróficas: el impuesto (taxAssessedValue) era 1.3x a 6.8x el precio real de venta, sin ninguna bandera de foreclosure que las delatara. El modelo las sobre-predecía sistemáticamente. Se agregaron features de ZIP relativas (tax\_vs\_zip\_ratio, is\_tax\_outlier) y un techo (cap) al percentil 95 de precio por ZIP.

**OOF MAPE 27.0% · Sharpe 1.074 vs 1.049 de Ronda 2**

Ronda 3-4 · 2026-06-27

MEJORA GRANDE

### Embeddings de imagenes (CLIP)

Se proceso la foto principal de cada propiedad con CLIP (red neuronal de vision-lenguaje) y se redujo a 32 componentes principales (PCA). También se calculó un score visual de deterioro (clip\_distress\_score) de forma zero-shot, sin entrenar nada específico.

**wMAPE 22.4% · Practice: Mean ROI 49.7% (+92% vs ronda anterior)**

*Leccion: El score visual de distress no mejoro el error promedio global, pero mejoro muchisimo la seleccion de que propiedades comprar en la subasta. Una señal puede no bajar el MAPE y aun asi ser muy valiosa para decidir.*

## Ronda 4 y el simulador propio

Ronda 4 · 2026-06-26

MEJORA GRANDE

### Regresion cuantil (percentil 35, no la media)

Detectamos que 2 propiedades causaron el 52% de todas las perdidas acumuladas (el modelo las habia sobre-predicho 5.7x y 8.8x el valor real). El error es asimetrico en este juego: sobreestimar destruye capital (compramos caro), subestimar solo cuesta la oportunidad (no compramos). Por eso se cambio el modelo para predecir el percentil 35 de la distribucion de precio en vez de la media.

**Practice: Mean ROI 44.47%, Sharpe 2.05, Prob. positivo 99.2%**

Simulador propio · 2026-06-26

OK

### Monte Carlo local calibrado con datos reales

Se construyo un simulador local que reproduce exactamente la mecanica del dashboard, calibrado con 946 ofertas reales observadas de 6 equipos rivales en una ronda de competencia ya jugada. Sirve para probar ideas sin gastar rondas reales ni subir al dashboard cada vez.

**En la calibracion inicial, nuestro equipo ganaba el 34.3% de las simulaciones**

## Rondas 5 y 6 — calibrando la agresividad

Ronda 5 · 2026-06-27

OK

### Mas conservador, penalidad dura a foreclosure

Se valido que  $\alpha=0.35$  (Ronda 4) era el punto correcto: bajarlo a 0.30 hundia el win rate de 34.3% a 12.4%. En una subasta Vickrey, predecir demasiado bajo simplemente regala las propiedades buenas a los competidores. Tambien se descarto last\_listing\_price como señal de distress: 22% del train tiene ese ratio bajo por precios historicos viejos, no por problemas reales de la propiedad.

**Confirma  $\alpha=0.35$  como calibracion base**

Ronda 6 · 2026-06-27

RESULTADO MIXTO

### Experimento: prediccion central + descuento quirurgico

Se probo  $\alpha=0.50$  (prediccion central, no conservadora) buscando comprar mas volumen, compensando con un descuento solo a las propiedades con peor score visual de distress (percentil 90).

**Mas volumen de compra, pero mayor tasa de errores costosos**

## Ronda 7 y Ronda 8 — el mejor modelo

Ronda 7 · 2026-07-03

RESULTADO MIXTO

### Punto intermedio: $\alpha=0.42$

En una ronda real, un equipo competidor gano comprando mucho mas volumen (15.4 props/ronda) que nosotros (9.7 props/ronda) aunque con menor precision por compra. Se probó  $\alpha=0.42$  como punto intermedio entre conservador y agresivo.

**Buscando 12-13 props/ronda con hit rate > 65%**

Ronda 8 · 2026-07-03

MEJORA GRANDE

### Fix quirurgico final (mejor modelo)

Se uso el resultado REAL de subastas ya jugadas (exports de la competencia) para identificar con certeza 6 propiedades donde el modelo se equivoco por hasta 4x el valor real. Se forzo su prediccion a  $\text{valor\_real} \times 0.92$ . Se agrego ademas un detector automatico para el train set: cualquier propiedad con  $\text{ratio prediccion/verdadero} > 2.5x$ .

**Se convirtio en el mejor modelo del proyecto hasta la calibracion final**



## Ronda 9 y la calibracion final

Ronda 9 · 2026-07-03 a 2026-07-18

NO FUNCIONO / EMPEORO

### Intento con texto (LLM local)

Se extrajeron ~18 features semanticas (condicion, vista, penthouse, amenities, señales de distress) de las descripciones de las propiedades usando un modelo de lenguaje corriendo LOCAL y gratis (Ollama, Qwen2.5 1.5B). Cobertura real: 48% de las propiedades tenian descripcion procesable.

*(ver el detalle completo en la seccion siguiente)*

### Pausado: no aporta con la calidad/cobertura de extraccion actual

*Leccion: Mas señal no es necesariamente buena señal si es ruidosa o parcial. Medir con una comparacion controlada (cambiar una sola cosa a la vez) evita atribuir una mejora o caída a la causa equivocada.*

Calibracion final · 2026-07-18


MEJORA GRANDE

### Barrido de escala sobre Ronda 8

Con Ronda 8 como mejor modelo, se probó multiplicar todas sus predicciones por un factor de escala (arriba y abajo de 1.0) para ver el efecto en el ROI. Primero se validó con el simulador local (calibrado con datos reales de subastas pasadas): se encontró una meseta óptima entre 0.80 y 0.85, con el Mean ROI subiendo de 8.26% a ~10.1-10.3% (+24% relativo). Se confirmó después en el dashboard real (Practice) con 3 corridas independientes, con distintos campos competitivos: la escala 0.83 le ganó de forma consistente y nunca revertida a Ronda 8 sin escalar, por un margen de 2x a 4x en Mean ROI.

### Mejora real, grande y reproducible — validada en 3 corridas independientes

## Ronda 9 — por que el texto no ayudo




### Prueba de proxies para detectar "distressed" en el test set

Ninguno predijo mejor que el azar (tasa base: 1.66%):

|                           |                               |
|---------------------------|-------------------------------|
| tag_foreclosure           | precision 0.0% (recall 0.0%)  |
| num_price_changes > 2     | precision 1.0% (recall 12.2%) |
| clip_distress_score > 0.7 | precision 2.0% (recall 4.6%)  |
| llm_is_fixer              | precision 3.4% (recall 17.8%) |
| raw_listing_to_tax < 0.5  | precision 1.6% (recall 22.3%) |

Conclusion: las perdidas catastróficas parecen ser idiosincráticas (circunstancias del vendedor), no un patrón detectable en fotos, tags o descripciones. Se descarto la corrección automática basada en proxies.

# La calibracion final: barrido de escala



Ojo: en este grafico local, la escala 0.85 muestra un pico un poco mas alto que 0.83— pero esta simulacion casera es aproximada, no la fuente de verdad (ver por que mas abajo).

Meseta optima entre escala 0.80 y 0.85: el Mean ROI local sube de 8.26% (sin escalar) a ~10.1-10.3% (+24% relativo). Validado en el dashboard real con 3 corridas independientes, cada una con un campo competitivo distinto:

| Corrida | N° modelos | Escala 0.83 | Escala 0.85 | Ronda 8 (sin escalar) |
|---------|------------|-------------|-------------|-----------------------|
| #1      | 3          | 76.5%       | 31.4%       | 27.0%                 |
| #2      | 7          | 61.2%       | 30.1%       | 15.5%                 |
| #3      | 9          | 46.9%       | 29.1%       | 11.0%                 |

El orden nunca se invirtio: escala 0.83 > escala 0.85 > Ronda 8 sin escalar, en las 3 corridas. Por eso se adopto la escala 0.83 con confianza.

## Criterio de Kelly aplicado a la subasta

En criollo: piensa 3 mesas de casino, una por segmento (SF, CONDO, RESTO). En cada mesa sabemos, por el historial, que tan seguido ganamos (Hit Rate) y cuanto ganamos o perdemos cuando pasa. El criterio de Kelly usa esos dos datos para decidir en que mesa conviene apostar mas fuerte y en cual mas flojo — en vez de apostar siempre lo mismo en las tres.

Ojo con un detalle: Kelly clasico asume que perder = perder toda la apuesta. Ese no es nuestro caso — si nos gana la subasta, no perdemos nada (el capital queda intacto). Lo adaptamos a lo que realmente puede pasar: ganar la subasta y pagar de mas, condicionado a que ganamos (formula:  $f^* = p/L - q/W$ , con  $p$ =Hit Rate,  $W$ =ganancia media y  $L$ =perdida media, ambas como fraccion del costo).

| Segmento | Hit Rate | Ganancia (W) | Perdida (L) | Kelly $f^*$ | Escala |
|----------|----------|--------------|-------------|-------------|--------|
| SF       | 75.0%    | 30.8%        | 19.3%       | 3.08        | 0.828  |
| CONDO    | 70.5%    | 30.4%        | 16.6%       | 3.28        | 0.832  |
| REST     | 72.7%    | 30.0%        | 17.8%       | 3.17        | 0.83   |

### Resultado honesto

Las 3 mesas salieron casi iguales (Hit Rate 70-75% en las tres) — no hay una claramente mejor que las otras. Por eso Kelly sugirio una escala casi identica en los 3 segmentos, muy cerca de la plana ya validada (0.83): el uso real que le dimos fue de verificacion, no de descubrimiento. Aun asi, escalar por segmento en vez de plano mejoro el Mean ROI local de 9.95% a 10.15%.

**Mean ROI local: escala plana 0.83 = 9.95% → escala Kelly por segmento = 10.15%**

#### LECCION: Validado en el dashboard real de Practice contra el campeón vigente

(scale083): kelly\_segment quedo practicamente empatado (32.57% vs 32.72% Mean ROI, -0.15pp). No lo supera, pero confirma que la escala 0.83 ya es una eleccion solida.

## Edge (valor esperado) por segmento x precio

En criollo: Kelly (Seccion 6) separo en 3 mesas por segmento y no encontro diferencias reales entre ellas. Edge va un paso mas — parte cada una de esas 3 mesas en otras 3 segun que tan cara predice el modelo que es la propiedad DENTRO de su propio segmento (barata / media / cara). Quedan 9 mesas en total.

Formalmente es lo mismo de siempre: si pudieramos repetir la misma subasta muchas veces, cuanto ganariamos en promedio?  $EV = P(\text{ganar}) \times (\text{valor\_real} - \text{costo pagado})$  — el costo solo se paga si ganamos.

| Bucket      | Hit Rate | EV (% del bid) | Escala sugerida |
|-------------|----------|----------------|-----------------|
| SF-bajo     | 78.6%    | 1.55%          | 0.806           |
| SF-medio    | 85.9%    | 1.88%          | 0.847           |
| SF-alto     | 89.9%    | 2.04%          | 0.867           |
| CONDO-bajo  | 78.8%    | 1.50%          | 0.8             |
| CONDO-medio | 86.0%    | 1.69%          | 0.823           |
| CONDO-alto  | 91.3%    | 1.86%          | 0.845           |
| REST-bajo   | 74.2%    | 1.47%          | 0.796           |
| REST-medio  | 86.4%    | 1.69%          | 0.823           |
| REST-alto   | 93.0%    | 2.10%          | 0.876           |

### Resultado honesto

A diferencia de las 3 mesas de Kelly, aca SI hay un patron consistente: en las 3 mesas 'caras' (Hit Rate ~90-93%) acertamos mucho mas seguido que en las 3 mesas 'baratas' (Hit Rate ~74-79%) — se repite igual en los 3 segmentos, no es casualidad. Usamos escalas mas agresivas en las mesas caras y mas conservadoras en las baratas, lo que mejoro el Mean ROI local de 9.95% a 10.22% — mas que Kelly solo.

**Mean ROI local: escala plana 0.83 = 9.95% → escala por bucket fino = 10.22%**

#### LECCION: En el dashboard real, comparado contra el campeón vigente, edge\_bucket

quedo por debajo (31.01% vs 32.72% Mean ROI, -1.71pp) pese al mejor Hit Rate (85.4%) y Sharpe (2.80) — su selectividad (9 props/sim vs 14) le costo volumen. La heterogeneidad que encontramos es real, pero no alcanza para superar la escala plana.

## Aprendizajes clave y recomendacion final

### 1. El error promedio no es lo que gana la competencia

En Ronda 4 encontramos que 2 propiedades causaron el 52% de todas las perdidas. Bajar el MAPE global importa menos que eliminar esos pocos errores extremos que destruyen capital.

### 2. Mas features no siempre ayudan

Ronda 2 (mas feature engineering) y Ronda 9 (features de texto por LLM) empeoraron el modelo. Hay que medir cada cambio, no asumir que suma.

### 3. Calibrar cuanto arriesgar importa tanto como el modelo en si

El ajuste final de escala (multiplicar las predicciones por 0.83) genero una mejora de ROI comparable a la de agregar imagenes — y costo una tarde de trabajo, no semanas.

### 4. Validar siempre en Practice antes de gastar una ronda real

Cada modelo nuevo se subio primero como OOF al tab Practice del dashboard. Solo se uso una ronda real cuando el Practice confirmaba una mejora.

### 5. Desconfiar de una sola corrida

La simulacion de Practice varia segun cuantos modelos compiten a la vez en la misma corrida. Antes de decidir, se repitieron las comparaciones clave 2 o 3 veces para confirmar que la diferencia era real y no ruido del muestreo Monte Carlo.

### 6. Comparar siempre contra el campeon vigente, no contra una version vieja

Kelly y Edge parecian ganar por mucho contra versiones sin escalar — pero comparados de forma justa contra scale083 (el campeon real), quedaron empatados o por debajo. Confirmar que un desafiante le gana al mejor modelo actual, no a un rival mas facil, evita una falsa sensacion de mejora.

#### MODELO ELEGIDO PARA LA PRESENTACION FINAL

#### **round8\_distress\_fix\_scale083.csv**

Es el modelo de Ronda 8 (tabular + imagenes CLIP + fix quirurgico de propiedades distressed) con todas las predicciones escaladas x0.83. Se probaron dos refinamientos mas finos para tratar de superarlo (Kelly por segmento y Edge por segmento x precio, secciones 6 y 7): ninguno le gano de forma clara en el dashboard real de Practice. La escala 0.83 queda confirmada como la mejor opcion disponible.