
UNIVERSIDAD AUSTRAL

MDM Austral 2026 · Labo 2

Property Investment Competition

Version imprimible para estudiar — sin colores ni fondos

Equipo SAM

Modelo final: round8_distress_fix_scale083.csv

Objetivo y mecanica de la competencia

Es una competencia de inversion inmobiliaria simulada. Predecimos el precio de venta de propiedades en Miami / Sur de Florida, y esa prediccion se usa para decidir, en una simulacion, si compramos cada propiedad y cuanto ofertamos.

Como funciona cada simulacion

- Cada propiedad tiene un precio de oferta (asking price) generado al azar con una distribucion normal (gaussiana), media -7% y desvio 35%: $\text{asking} = \text{valor_real} \times (1 + \text{Normal}(-7\%, 35\%))$. En criollo: el asking suele salir un poco por debajo del valor real, pero con mucha variacion — a veces sale muy bajo, a veces muy alto.
- Compramos solo si nuestra prediccion supera el asking price en un 8% ($\text{pred} > \text{asking} \times 1.08$).
- Si compramos, ofertamos $\text{pred} \times 0.85$ en una subasta Vickrey (gana el mayor postor pero paga el precio del segundo postor). Ese $\times 0.85$ es una regla fija de la competencia, no algo que ajustamos nosotros — lo que si calibramos es la prediccion que entra a esa formula (alpha, escala).
- Se corren 1,000 simulaciones Monte Carlo, 4 rondas por simulacion, capital de \$5M por ronda.
- Gana el equipo con mayor Mean ROI promedio (metrica principal). El Win Rate es secundario: no decide el ganador.

Que significa esto en la practica

Si predecimos MUY POR ENCIMA del valor real, compramos propiedades caras y perdemos plata (perdida real). Si predecimos por debajo, simplemente no compramos esa propiedad (perdemos la oportunidad, pero no perdemos capital). Este desbalance explica varias decisiones de diseno del proyecto (Ronda 4).

Los datos con los que trabajamos

Dos conjuntos de propiedades

- Train: 11,840 propiedades con precio de venta real conocido — con esto entrenamos los modelos.
- Test: 5,038 propiedades sin precio — sobre estas generamos las predicciones que se usan en la competencia real.

Que sabemos de cada propiedad

- Datos estructurados: tamaño, habitaciones, baños, antigüedad, ubicación, impuestos, escuelas cercanas, HOA, historial de precio.
- Fotos de la propiedad (usadas en Rondas 3 a 8 via embeddings CLIP).
- Descripción de texto (usada en el experimento de Ronda 9).

Dificultades del dataset

- Faltantes importantes: lotAreaValue (45% de las filas), last_listing_price (33%).
- Features "filtradas" (leaky): taxAssessedValue y variables de impuestos se usan con cuidado, no como única fuente de señal.
- Menos del 2% de las propiedades son ventas atípicas — y terminaron siendo el factor más importante de todo el proyecto (Rondas 3, 4 y 8).

Ronda 1, Ronda 2, Ronda 3

Ronda 1 · 2026-06-09

[OK]

Baseline LightGBM

Primer modelo: LightGBM con todos los features tabulares disponibles y validacion cruzada 5-fold.

wMAPE ~26% · Practice: Mean ROI 23.27%, Sharpe 1.15

Ronda 2 · 2026-06-09

[NO FUNCIONO]

Segmentacion + Feature Engineering

Dos tecnicas distintas, probadas juntas en la misma ronda.

(1) Segmentacion: en vez de un solo modelo, se entrenaron 3 modelos separados, uno por tipo de propiedad (SINGLE_FAMILY / CONDO / RESTO) — no es una columna nueva, es una decision de arquitectura.

(2) Feature engineering: columnas nuevas calculadas a partir de las existentes — ratios financieros (ej. $\text{tax_per_sqft} = \text{impuesto} / \text{superficie}$), scores compuestos (ej. $\text{luxury_score} = \text{suma de pileta} + \text{vista al agua} + \text{garage} + \text{HOA alto}$) e interacciones (ej. $\text{school_x_area} = \text{rating de escuela} \times \text{superficie}$).

Practice: Mean ROI 20.63%, Sharpe 1.06 — PEOR que Ronda 1

Leccion: Mas feature engineering no garantiza mejor resultado. Hay que medir cada cambio en Practice antes de asumir que mejora. Como las dos tecnicas se probaron juntas, no sabemos cual de las dos causo la caida.

Ronda 3 · 2026-06-11

[OK]

Deteccion de "distressed sales ocultas"

Encontramos 16 propiedades con perdidas catastroficas: el impuesto (taxAssessedValue) era 1.3x a 6.8x el precio real de venta, sin ninguna bandera de foreclosure que las delatara. El modelo las sobre-predecia sistematicamente. Se agregaron features de ZIP relativas (tax_vs_zip_ratio, is_tax_outlier) y un techo (cap) al percentil 95 de precio por ZIP.

OOF MAPE 27.0% · Sharpe 1.074 vs 1.049 de Ronda 2

Ronda 3-4, Ronda 4, Simulador propio

Ronda 3-4 · 2026-06-27

[FUNCIONO]

Embeddings de imagenes (CLIP)

Se proceso la foto principal de cada propiedad con CLIP (red neuronal de vision-lenguaje) y se redujo a 32 componentes principales (PCA). Tambien se calculo un score visual de deterioro (clip_distress_score) de forma zero-shot, sin entrenar nada especifico.

wMAPE 22.4% · Practice: Mean ROI 49.7% (+92% vs ronda anterior)

Leccion: El score visual de distress no mejoro el error promedio global, pero mejoro muchisimo la seleccion de que propiedades comprar en la subasta. Una señal puede no bajar el MAPE y aun asi ser muy valiosa para decidir.

Ronda 4 · 2026-06-26

[FUNCIONO]

Regresion cuantil (percentil 35, no la media)

Detectamos que 2 propiedades causaron el 52% de todas las perdidas acumuladas (el modelo las habia sobre-predicho 5.7x y 8.8x el valor real). El error es asimetrico en este juego: sobreestimar destruye capital (compramos caro), subestimar solo cuesta la oportunidad (no compramos). Por eso se cambio el modelo para predecir el percentil 35 de la distribucion de precio en vez de la media.

Practice: Mean ROI 44.47%, Sharpe 2.05, Prob. positivo 99.2%

Simulador propio · 2026-06-26

[OK]

Monte Carlo local calibrado con datos reales

Se construyo un simulador local que reproduce exactamente la mecanica del dashboard, calibrado con 946 ofertas reales observadas de 6 equipos rivales en una ronda de competencia ya jugada. Sirve para probar ideas sin gastar rondas reales ni subir al dashboard cada vez.

En la calibracion inicial, nuestro equipo ganaba el 34.3% de las simulaciones

Ronda 5, Ronda 6, Ronda 7

Ronda 5 · 2026-06-27

[OK]

Mas conservador, penalidad dura a foreclosure

Se valido que $\alpha=0.35$ (Ronda 4) era el punto correcto: bajarlo a 0.30 hundia el win rate de 34.3% a 12.4%. En una subasta Vickrey, predecir demasiado bajo simplemente regala las propiedades buenas a los competidores. Tambien se descarto last_listing_price como señal de distress: 22% del train tiene ese ratio bajo por precios historicos viejos, no por problemas reales de la propiedad.

Confirma $\alpha=0.35$ como calibracion base

Ronda 6 · 2026-06-27

[MIXTO]

Experimento: prediccion central + descuento quirurgico

Se probo $\alpha=0.50$ (prediccion central, no conservadora) buscando comprar mas volumen, compensando con un descuento solo a las propiedades con peor score visual de distress (percentil 90).

Mas volumen de compra, pero mayor tasa de errores costosos

Ronda 7 · 2026-07-03

[MIXTO]

Punto intermedio: $\alpha=0.42$

En una ronda real, un equipo competidor gano comprando mucho mas volumen (15.4 props/ronda) que nosotros (9.7 props/ronda) aunque con menor precision por compra. Se probo $\alpha=0.42$ como punto intermedio entre conservador y agresivo.

Buscando 12-13 props/ronda con hit rate > 65%

Ronda 8, Ronda 9, Calibracion final

Ronda 8 · 2026-07-03

[FUNCIONO]

Fix quirurgico final (mejor modelo)

Se uso el resultado REAL de subastas ya jugadas (exports de la competencia) para identificar con certeza 6 propiedades donde el modelo se equivoco por hasta 4x el valor real. Se forzo su prediccion a $\text{valor_real} \times 0.92$. Se agrego ademas un detector automatico para el train set: cualquier propiedad con $\text{ratio prediccion/verdadero} > 2.5x$.

Se convirtio en el mejor modelo del proyecto hasta la calibracion final

Ronda 9 · 2026-07-03 a 2026-07-18

[NO FUNCIONO]

Intento con texto (LLM local)

Se extrajeron ~18 features semanticas (condicion, vista, penthouse, amenities, señales de distress) de las descripciones de las propiedades usando un modelo de lenguaje corriendo LOCAL y gratis (Ollama, Qwen2.5 1.5B). Cobertura real: 48% de las propiedades tenian descripcion procesable.

(ver el detalle completo en la seccion siguiente)

Pausado: no aporta con la calidad/cobertura de extraccion actual

Leccion: Mas señal no es necesariamente buena señal si es ruidosa o parcial. Medir con una comparacion controlada (cambiar una sola cosa a la vez) evita atribuir una mejora o caida a la causa equivocada.

Calibracion final · 2026-07-18


[FUNCIONO]

Barrido de escala sobre Ronda 8

Con Ronda 8 como mejor modelo, se probó multiplicar todas sus predicciones por un factor de escala (arriba y abajo de 1.0) para ver el efecto en el ROI. Primero se validó con el simulador local (calibrado con datos reales de subastas pasadas): se encontró una meseta óptima entre 0.80 y 0.85, con el Mean ROI subiendo de 8.26% a ~10.1-10.3% (+24% relativo). Se confirmó después en el dashboard real (Practice) con 3 corridas independientes, con distintos campos competitivos: la escala 0.83 le ganó de forma consistente y nunca revertida a Ronda 8 sin escalar, por un margen de 2x a 4x en Mean ROI.

Mejora real, grande y reproducible — validada en 3 corridas independientes

Ronda 9 — por que el texto no ayudo




Prueba de proxies para detectar "distressed" en el test set

Ninguno predijo mejor que el azar (tasa base: 1.66%):

tag_foreclosure	precision 0.0% (recall 0.0%)
num_price_changes > 2	precision 1.0% (recall 12.2%)
clip_distress_score > 0.7	precision 2.0% (recall 4.6%)
llm_is_fixer	precision 3.4% (recall 17.8%)
raw_listing_to_tax < 0.5	precision 1.6% (recall 22.3%)

Conclusion: las perdidas catastróficas parecen ser idiosincráticas (circunstancias del vendedor), no un patrón detectable en fotos, tags o descripciones. Se descarto la corrección automática basada en proxies.

La calibracion final: barrido de escala



Ojo: en este grafico local, la escala 0.85 muestra un pico un poco mas alto que 0.83—pero esta simulacion casera es aproximada, no la fuente de verdad (ver por que mas abajo).

Meseta optima entre escala 0.80 y 0.85: el Mean ROI local sube de 8.26% (sin escalar) a ~10.1-10.3% (+24% relativo). Validado en el dashboard real con 3 corridas independientes, cada una con un campo competitivo distinto:

Corrida	N° modelos	Escala 0.83	Escala 0.85	Ronda 8 (sin escalar)
#1	3	76.5%	31.4%	27.0%
#2	7	61.2%	30.1%	15.5%
#3	9	46.9%	29.1%	11.0%

El orden nunca se invirtio: escala 0.83 > escala 0.85 > Ronda 8 sin escalar, en las 3 corridas. Por eso se adopto la escala 0.83 con confianza.

Criterio de Kelly aplicado a la subasta

En criollo: piensa 3 mesas de casino, una por segmento (SF, CONDO, RESTO). En cada mesa sabemos, por el historial, que tan seguido ganamos (Hit Rate) y cuanto ganamos o perdemos cuando pasa. El criterio de Kelly usa esos dos datos para decidir en que mesa conviene apostar mas fuerte y en cual mas flojo — en vez de apostar siempre lo mismo en las tres.

Ojo con un detalle: Kelly clasico asume que perder = perder toda la apuesta. Ese no es nuestro caso — si nos gana la subasta, no perdemos nada (el capital queda intacto). Lo adaptamos a lo que realmente puede pasar: ganar la subasta y pagar de mas, condicionado a que ganamos (formula: $f^* = p/L - q/W$, con p =Hit Rate, W =ganancia media y L =perdida media, ambas como fraccion del costo).

Segmento	Hit Rate	Ganancia (W)	Perdida (L)	Kelly f*	Escala
SF	75.0%	30.8%	19.3%	3.08	0.828
CONDO	70.5%	30.4%	16.6%	3.28	0.832
REST	72.7%	30.0%	17.8%	3.17	0.83

Resultado honesto

Las 3 mesas salieron casi iguales (Hit Rate 70-75% en las tres) — no hay una claramente mejor que las otras. Por eso Kelly sugirio una escala casi identica en los 3 segmentos, muy cerca de la plana ya validada (0.83): el uso real que le dimos fue de verificacion, no de descubrimiento. Aun asi, escalar por segmento en vez de plano mejoro el Mean ROI local de 9.95% a 10.15%.

RESULTADO

Mean ROI local: escala plana 0.83 = 9.95% -> escala Kelly por segmento = 10.15%

LECCION

Validado en el dashboard real de Practice contra el campeon vigente (scale083): kelly_segment quedo practicamente empatado (32.57% vs 32.72% Mean ROI, -0.15pp). No lo supera, pero confirma que la escala 0.83 ya es una eleccion solida.

Edge (valor esperado) por segmento x precio

En criollo: Kelly (Seccion 6) separo en 3 mesas por segmento y no encontro diferencias reales entre ellas. Edge va un paso mas — parte cada una de esas 3 mesas en otras 3 segun que tan cara predice el modelo que es la propiedad DENTRO de su propio segmento (barata / media / cara). Quedan 9 mesas en total.

Formalmente es lo mismo de siempre: si pudieramos repetir la misma subasta muchas veces, cuanto ganariamos en promedio? $EV = P(\text{ganar}) \times (\text{valor_real} - \text{costo pagado})$ — el costo solo se paga si ganamos.

Bucket	Hit Rate	EV (% del bid)	Escala sugerida
SF-bajo	78.6%	1.55%	0.806
SF-medio	85.9%	1.88%	0.847
SF-alto	89.9%	2.04%	0.867
CONDO-bajo	78.8%	1.50%	0.8
CONDO-medio	86.0%	1.69%	0.823
CONDO-alto	91.3%	1.86%	0.845
REST-bajo	74.2%	1.47%	0.796
REST-medio	86.4%	1.69%	0.823
REST-alto	93.0%	2.10%	0.876

Resultado honesto

A diferencia de las 3 mesas de Kelly, aca SI hay un patron consistente: en las 3 mesas 'caras' (Hit Rate ~90-93%) acertamos mucho mas seguido que en las 3 mesas 'baratas' (Hit Rate ~74-79%) — se repite igual en los 3 segmentos, no es casualidad. Usamos escalas mas agresivas en las mesas caras y mas conservadoras en las baratas, lo que mejoro el Mean ROI local de 9.95% a 10.22% — mas que Kelly solo.

RESULTADO

Mean ROI local: escala plana 0.83 = 9.95% -> escala por bucket fino = 10.22%

LECCION

En el dashboard real, comparado contra el campeon vigente, edge_bucket quedo por debajo (31.01% vs 32.72% Mean ROI, -1.71pp) pese al mejor Hit Rate (85.4%) y Sharpe (2.80) — su selectividad (9 props/sim vs 14) le costo volumen. La heterogeneidad que encontramos es real, pero no alcanza para superar la escala plana.

Aprendizajes clave y recomendacion final

1. El error promedio no es lo que gana la competencia

En Ronda 4 encontramos que 2 propiedades causaron el 52% de todas las perdidas. Bajar el MAPE global importa menos que eliminar esos pocos errores extremos que destruyen capital.

2. Mas features no siempre ayudan

Ronda 2 (mas feature engineering) y Ronda 9 (features de texto por LLM) empeoraron el modelo. Hay que medir cada cambio, no asumir que suma.

3. Calibrar cuanto arriesgar importa tanto como el modelo en si

El ajuste final de escala (multiplicar las predicciones por 0.83) genero una mejora de ROI comparable a la de agregar imagenes — y costo una tarde de trabajo, no semanas.

4. Validar siempre en Practice antes de gastar una ronda real

Cada modelo nuevo se subio primero como OOF al tab Practice del dashboard. Solo se uso una ronda real cuando el Practice confirmaba una mejora.

5. Desconfiar de una sola corrida

La simulacion de Practice varia segun cuantos modelos compiten a la vez en la misma corrida. Antes de decidir, se repitieron las comparaciones clave 2 o 3 veces para confirmar que la diferencia era real y no ruido del muestreo Monte Carlo.

6. Comparar siempre contra el campeon vigente, no contra una version vieja

Kelly y Edge parecian ganar por mucho contra versiones sin escalar — pero comparados de forma justa contra scale083 (el campeon real), quedaron empatados o por debajo. Confirmar que un desafiante le gana al mejor modelo actual, no a un rival mas facil, evita una falsa sensacion de mejora.

MODELO ELEGIDO PARA LA PRESENTACION FINAL

round8_distress_fix_scale083.csv

Es el modelo de Ronda 8 (tabular + imagenes CLIP + fix quirurgico de propiedades distressed) con todas las predicciones escaladas x0.83. Se probaron dos refinamientos mas finos para tratar de superarlo (Kelly por segmento y Edge por segmento x precio, secciones 6 y 7): ninguno le gano de forma clara en el dashboard real de Practice. La escala 0.83 queda confirmada como la mejor opcion disponible.

20 preguntas y respuestas (1-9 de 20)

1. Que mide el wMAPE y en que se diferencia del Mean ROI?

wMAPE mide el error de prediccion de precio (cuanto se equivoca el modelo, en %, ponderado por precio real). Mean ROI mide la ganancia real de invertir siguiendo esas predicciones en la simulacion de subasta. Son independientes: un modelo puede tener buen wMAPE y mal ROI, o al revés (paso en Ronda 3-4 y en Ronda 9).

2. Como se genera el asking price de cada propiedad en la simulacion?

asking = valor_real x (1 + shock), con shock de una distribucion normal, media -7% y desvio 35%. En promedio el asking esta un poco por debajo del valor real, pero con mucha variacion.

3. Que es una subasta Vickrey y por que la usa la competencia?

Es una subasta de segundo precio: gana el que mas ofrece, pero paga lo que ofrecio el segundo. Reduce el incentivo a subestimar cuanto vale algo para uno.

4. Cuantas propiedades tiene el train set y cuantas el test set?

Train: 11,840 propiedades con precio real conocido. Test: 5,038 sin precio, sobre las que se generan las predicciones de la competencia real.

5. Que metrica define al ganador: Mean ROI o Win Rate?

Mean ROI (promedio de ganancia en las 1,000 simulaciones). Win Rate es secundario, no decide el ganador.

6. Por que el 0.85 de la oferta no es algo que calibraron ustedes?

Es una regla fija de la mecanica de la competencia (oferta = prediccion x 0.85), dada por el curso. Lo que si calibraron fue la prediccion que entra a esa formula: el alpha de la regresion cuantil y la escala final (0.83).

7. Que diferencia hay entre segmentacion y feature engineering en Ronda 2?

Segmentacion = entrenar 3 modelos separados por tipo de propiedad (arquitectura, no una columna). Feature engineering = columnas nuevas (ratios, scores compuestos, interacciones). Se probaron juntas en la misma ronda, asi que no se puede aislar cual de las dos causo la caida.

8. Que son los embeddings CLIP y para que sirvio el PCA?

CLIP es una red neuronal ya entrenada que convierte cada foto en 512 numeros que resumen su contenido visual. PCA comprime esos 512 numeros a 32, quedandose con lo mas relevante, antes de dárselo al modelo.

9. Por que el fix de Ronda 8 corrige train y test de forma distinta?

En test solo se conocen los valores reales de 6 propiedades puntuales (por resultados de subastas ya jugadas), asi que se corrigen a mano. En train se conoce el valor real de las 11,840 propiedades, asi que se arma una regla automatica (ratio prediccion/verdadero > 2.5x).

20 preguntas y respuestas (10-18 de 20)

10. Diferencia entre las 6 de test y la detección automática en train?

Las 6 de test se identificaron con certeza porque ya se jugó esa subasta y se vio el resultado real. La regla de train es estadística (umbral de ratio), aplicada a gran escala sin mirar caso por caso.

11. Por qué el clip_distress_score mejora el ROI sin bajar el MAPE?

El MAPE es un promedio sobre todas las propiedades; el score ayuda a evitar comprar específicamente las peores (visualmente deterioradas), pocas pero muy costosas si se compran mal. Cambia la decisión de compra más de lo que cambia la predicción promedio.

12. Por qué sobreestimar es más costoso que subestimar?

Si se sobreestima, se puede ganar la subasta pagando de más -> pérdida real de capital. Si se subestima, simplemente no se compra esa propiedad -> se pierde la oportunidad, pero no plata. Por eso conviene sesgar la predicción hacia abajo (percentil 35).

13. En el gráfico local 0.85 gana — por qué igual eligieron 0.83?

Ese gráfico es una simulación aproximada casera (datos de una ronda vieja de competidores). La decisión real se tomó subiendo ambas escalas al dashboard real de Practice: ahí 0.83 le gana a 0.85 en las 3 corridas independientes que se hicieron.

14. ¿Qué asume Kelly clásico que no se cumple en esta subasta?

Que perder = perder toda la apuesta. Aquí, si se pierde la subasta, no se pierde nada (el capital queda intacto) — solo se pierde si se gana la subasta pagando de más. Se adaptó la fórmula a esa condición.

15. Por qué los proxies para detectar distressed no funcionaron?

Se midió precisión y recall de foreclosure, fotos, tags y texto contra los casos reales — ninguno superó la tasa base (~1.66%, o sea, adivinar al azar). Las pérdidas catastróficas parecen ser idiosincráticas, no un patrón detectable en los datos disponibles.

16. Por qué comparar Kelly/Edge contra round8 sin escalar era engañoso?

Round8 sin escalar es la peor versión conocida del modelo. Cualquier variante nueva le gana fácil a esa base débil. La comparación justa es contra el campeón real (scale083), y ahí la ventaja de Kelly y Edge se achica o desaparece.

17. Por qué Edge perdió en la prueba real si localmente mejoraba más?

Edge se volvió más selectivo (compraba menos propiedades, ~9 vs ~14-17 del campeón) buscando mayor Hit Rate. Eso le dio mejor precisión pero menos volumen, y en el juego real el volumen importa tanto como acertar.

18. ROI alto y variable vs ROI un poco más bajo y estable — ¿cual conviene?

Según las reglas, gana el mayor Mean ROI promedio, así que en el margen el ROI más alto gana aunque sea más variable. Pero el curso también valora el Std bajo como objetivo secundario — por eso Kelly (mejor Sharpe) es un candidato razonable si se prioriza consistencia.

20 preguntas y respuestas (19-20 de 20)

19. Por que no alcanza con correr Practice una sola vez?

La simulacion varia segun cuantos modelos compiten a la vez y tiene ruido de muestreo Monte Carlo. Se repitieron las comparaciones clave 2-3 veces con distintos campos competitivos antes de decidir.

20. Que retomarian con un mes mas de trabajo?

Probablemente texto/LLM, pero cambiando el modelo de extraccion (uno mas grande que qwen2.5:1.5b) y mejorando la cobertura (hoy 48%) antes de reintentarlo — el problema no era el enfoque sino la calidad/coertura de los datos de entrada.

preguntas 1-8 de 15

1. Que significa wMAPE?

- A) Win/Mean Auction Profit Estimate
- B) Una medida de riesgo del portafolio
- C) Weighted Mean Absolute Percentage Error — error de prediccion de precio
- D) El porcentaje de subastas ganadas

2. Si compramos y pagamos de mas por una propiedad...

- A) No pasa nada, se ajusta automaticamente
- B) Se cancela la compra
- C) Ganamos el Win Rate igual
- D) Perdemos capital real

3. Cual es la metrica principal que define al ganador de la competencia?

- A) Mean ROI
- B) wMAPE
- C) Win Rate
- D) Sharpe

4. El multiplicador de la oferta (prediccion x 0.85)...

- A) Lo calibramos nosotros en la Ronda 7
- B) Es una regla fija de la competencia
- C) Cambia segun el segmento
- D) Se ajusto junto con la escala 0.83

5. En la Ronda 2, segmentacion se refiere a...

- A) Una columna nueva que indica el tipo de propiedad
- B) Dividir el dataset en train/test
- C) Un score compuesto de lujo
- D) Entrenar 3 modelos separados por tipo de propiedad

6. Que hace PCA con los embeddings de CLIP?

- A) Los comprime de 512 a 32 numeros, conservando lo mas relevante
- B) Los entrena desde cero para propiedades
- C) Calcula el score de distress
- D) Elimina las fotos de mala calidad

7. Por que se uso el percentil 35 en vez de la media?

- A) Porque es mas facil de calcular
- B) Porque el dataset tiene 35% de datos faltantes
- C) Porque sobreestimar es mas costoso que subestimar en este juego
- D) Porque asi lo pide la competencia

8. Las 6 propiedades del fix quirurgico en test se identificaron...

- A) Con un modelo de deteccion automatica
- B) Mirando resultados reales de subastas ya jugadas
- C) Al azar
- D) Usando el clip_distress_score

preguntas 9-15 de 15

9. Al probar proxies (fotos, tags, texto) para detectar distressed en test...

- A) Ninguno predijo mejor que el azar
- B) Funcionaron mejor que el modelo principal
- C) Solo el tag de foreclosure funciono bien
- D) Funcionaron, pero solo en CONDO

10. Kelly clasico asume que perder significa...

- A) Pagar de mas en la subasta
- B) No participar en la subasta
- C) Bajar el Hit Rate
- D) Perder toda la apuesta

11. En el barrido de escala, el grafico local mostraba que...

- A) 0.83 era claramente el mejor punto
- B) 0.85 tenia un pico un poco mas alto que 0.83
- C) 1.00 (sin escalar) era el mejor
- D) No habia diferencia entre escalas

12. Por que se eligio 0.83 en vez de 0.85 pese al grafico local?

- A) Porque en 3 corridas reales del dashboard, 0.83 le gano a 0.85
- B) Por practicidad, es un numero redondo
- C) Porque 0.85 no se pudo probar
- D) Porque el profesor lo indico

13. Edge, comparado con Kelly, encontro diferencias reales al cortar por...

- A) Segmento solamente
- B) Fecha de la venta
- C) Segmento x tercil de precio dentro del segmento
- D) Cantidad de fotos

14. Por que Edge perdio en la prueba real pese a mejorar mas en la simulacion local?

- A) Por un error en el codigo
- B) Porque no se probó nunca en Practice
- C) Porque el Hit Rate bajo
- D) Porque compro muchas menos propiedades (menos volumen)

15. Cual fue el modelo final elegido para la presentacion?

- A) oof_round9_text_llm_llm5704
- B) round8_distress_fix_scale083
- C) round8_kelly_segment
- D) round8_edge_bucket

Respuestas correctas

Tapa esta pagina mientras respondes las anteriores.

1. C

2. D

3. A

4. B

5. D

6. A

7. C

8. B

9. A

10. D

11. B

12. A

13. C

14. D

15. B